



NANO CHALLENGE · ANÁLISE DE DADOS

Motor de Predição de Popularidade Musical

Estimando o alcance de uma faixa antes do lançamento, a partir de dados do Spotify

Residência em Inteligência Artificial · Instituto Eldorado

Parceria: Universidade de Brasília e Lab Livre · Coordenação: Softex · Apoio: MCTI

Jhiovana Ribeiro · Cauan Soares · Larissa Giffoni · Marcos Bittar · Pedro Henrique de Sousa

CONTEXTO

Milhares de faixas novas, poucas evidências para decidir

- O mercado de streaming recebe dezenas de milhares de faixas novas todos os dias.
- Selos, artistas e curadores tomam decisões de orçamento e posicionamento sem saber, com antecedência, o alcance provável de uma música.
- O desafio deste projeto foi transformar dados musicais em evidências objetivas para essas decisões.

A BASE DE DADOS DO PROJETO

114.000

faixas musicais

114

gêneros musicais

31.437

artistas distintos

Quem precisa prever o alcance de uma música



Selos e gravadoras

precisam direcionar orçamento de marketing para as faixas com maior potencial de alcance.



Artistas

precisam entender seu posicionamento de mercado antes de um lançamento.



Curadores de playlist

precisam equilibrar catálogos editoriais com um critério objetivo de popularidade esperada.

PERGUNTA CENTRAL DO DESAFIO

“Como transformar dados musicais em evidências para apoiar decisões de negócio e prever o alcance de uma faixa?”

SOLUÇÃO

Um modelo que estima a popularidade de 0 a 100

O modelo combina três grupos de informação para gerar a nota de popularidade de uma faixa.



Áudio

Dançabilidade, energia, volume, andamento e demais características sonoras da faixa.



Gênero

Codificado pela média histórica de popularidade de cada um dos 114 gêneros.



Artista


Codificado com Target Encoding e validação cruzada, para representar o histórico do artista sem copiar a resposta.

Da faixa bruta à nota de popularidade



A validação foi feita com K-Fold Out-Of-Fold, garantindo que nenhuma música use a própria nota para calcular a média do seu artista.

Cinco algoritmos comparados, um modelo escolhido




MODELO ESCOLHIDO

Random Forest Regressor

- Captura relações não lineares entre artista, gênero e áudio.
- Não depende da escala das variáveis.
- Reduz overfitting ao combinar cem árvores treinadas com amostras diferentes.

O que realmente determina o sucesso de uma faixa



O artista domina

Mais da metade do peso preditivo vem do histórico do artista.

O gênero define o ponto de partida

Estabelece a audiência potencial imediata da faixa.

O áudio ajusta o resultado

Cada característica sonora contribui de forma equilibrada e pontual.

RESULTADOS

O modelo final em três números

64,24%

R^2 , poder de explicação

da variação de popularidade explicada pelo modelo

8,06

MAE, erro médio absoluto

pontos de distância entre a nota prevista e a nota real, em uma escala de 0 a 100

13,39

RMSE

penalidade para os erros mais graves do modelo

Onde a previsão entra na decisão de negócio



Selos e gravadoras

Direcionam orçamento de marketing para as faixas com maior potencial de alcance.



Artistas


Entendem seu posicionamento de mercado antes de um lançamento.



Curadores de playlist

Equilibram catálogos editoriais com um critério objetivo de popularidade esperada.

Como o modelo passa a operar em produção



Artistas sem histórico recebem automaticamente a média global de popularidade, garantindo que a API sempre responda.

PRÓXIMO PASSO

O modelo está pronto para um piloto em produção



Piloto com dados ao vivo

Testar a arquitetura proposta com um catálogo em atualização contínua.



Parceria com um selo ou curadoria

Validar o modelo em um cenário real de decisão de marketing ou de playlist.



Novas fontes de dados

Incorporar sinais de marketing e redes sociais para reduzir a margem de erro atual.

Agradecemos a atenção. Estamos à disposição para perguntas.