

Relatório Técnico: Motor de Predição de Popularidade Musical com Machine Learning

Projeto: Motor de Predição de Popularidade Musical no Spotify

Contexto: Nano-Challenge: Spotify Dataset

Programa: Residência em IA | **Execução:** Instituto Eldorado

Parceria: Universidade de Brasília (UnB) & Lab Livre | **Coordenação:** Softex | **Apoio:** MCTI

Área de Concentração: Ciência de Dados, Engenharia de Features e Sistemas de Machine Learning

Equipe:

- Jhiovana Ribeiro
- Cauan Soares
- Larissa Giffoni
- Marcos Bittar
- Pedro Henrique de Sousa

Repositório: [jhsribeiro/spotify-popularity-prediction](https://github.com/jhsribeiro/spotify-popularity-prediction)

Sumário

- [Resumo Executivo](#)
- [1. Contexto de Negócio e Objetivos](#)
- [2. Entendimento dos Dados](#)
- [3. Preparação dos Dados e Engenharia de Features](#)
- [4. Respostas às Guiding Questions](#)
- [5. Escolha e Funcionamento do Random Forest](#)
- [6. Validação Cruzada K-Fold e Comparação dos Modelos](#)
- [7. O que Realmente Importa: Análise de Importância das Features](#)
- [8. Arquitetura Proposta para Produção](#)
- [9. Visualizações Gráficas](#)
- [10. Conclusão](#)

Resumo Executivo

Este relatório documenta a metodologia, o pipeline de dados e os resultados obtidos no desenvolvimento do **Motor de Predição de Popularidade Musical**, construído a partir de uma base com 114.000 faixas musicais distribuídas em 114 gêneros e mais de 31.000 artistas do Spotify.

O objetivo do projeto foi entender o que realmente move o sucesso de uma música e construir um modelo capaz de estimar seu índice de popularidade (0 a 100). Para lidar com a alta quantidade de artistas e gêneros sem vaziar respostas para o modelo, aplicamos a técnica de **Target Encoding com validação cruzada Out-Of-Fold (K-Fold, K=5)**.

Para a modelagem preditiva, selecionamos o **Random Forest Regressor**, que superou com folga modelos lineares e algoritmos de boosting (XGBoost e LightGBM). O modelo final alcançou:

- R^2 (**Poder de Explicação**): **64,24%** da variação da popularidade explicada.
- **MAE (Erro Médio Absoluto)**: apenas **8,06 pontos** em uma escala de 0 a 100.
- **RMSE (Raiz do Erro Quadrático Médio)**: **13,39 pontos**.

A análise de importância de variáveis comprovou que o sucesso no Spotify é ditado principalmente pelo **prestígio histórico do artista (56,57%)** e pelo **gênero musical (8,93%)**, enquanto as características puramente de áudio (como dançabilidade, energia, tempo e volume) atuam como moduladores finos secundários.

1. Contexto de Negócio e Objetivos

No mercado de streaming musical, dezenas de milhares de novas faixas são lançadas diariamente. Saber com antecedência o potencial de alcance de uma música ajuda selos a direcionarem orçamentos de marketing, auxilia artistas a entenderem seu posicionamento de mercado e permite que curadores equilibrem playlists editoriais.

O desafio central deste projeto, guiado pela metodologia *Challenge Based Learning* (CBL), sintetiza-se na questão: **"Como transformar dados musicais em evidências para apoiar decisões de negócio e prever o alcance de uma faixa?"**.

Objetivos Principais

- 1. **Higienizar e Auditar o Dataset:** Tratar inconsistências, dados nulos e duplicatas no catálogo do Spotify.
- 2. **Engenharia de Features sem Data Leakage:** Implementar **Target Encoding** com particionamento **Out-Of-Fold (K-Fold)** para transformar artistas e gêneros em pesos numéricos reais sem sobreajuste (*overfitting*).
- 3. **Responder às Perguntas Norteadoras (*Guiding Questions*):** Apresentar respostas diretas e embasadas nos dados para as 7 perguntas centrais do desafio.
- 4. **Treinar e Justificar o Modelo Vencedor:** Comparar diferentes algoritmos e justificar a escolha do **Random Forest Regressor**, validando-o com **K-Fold Cross-Validation**.
- 5. **Estruturar a Arquitetura de Produção:** Desenhar e implementar o fluxo prático de engenharia para colocar o modelo em operação contínua, combinando um backend em **FastAPI (Python)** e um frontend interativo em **React (Vite)**.

2. Entendimento dos Dados

O conjunto de dados reúne **114.000 músicas**, cobrindo 114 gêneros (exatamente 1.000 faixas por gênero no conjunto original) e 31.437 artistas.

A Variável Alvo (popularity)

A popularidade varia de **0 a 100** e é calculada internamente pelo Spotify. Ela considera não apenas o total de reproduções ao longo da história, mas principalmente a **frequência e recência das reproduções**. Músicas tocadas muitas vezes recentemente têm notas muito mais altas do que músicas antigas com volumes acumulados altos, mas ouvintes diários moderados.

Dicionário Prático das Variáveis

Variável	Tipo	O que significa?
popularity	Inteiro (0 a 100)	Alvo a ser previsto. Grau de alcance e consumo recente da música.
artists	Texto	Nome do artista principal ou colaboradores da faixa.
track_genre	Texto	Gênero musical atribuído pelo Spotify (114 categorias).

Variável	Tipo	O que significa?
duration_ms	Inteiro	Duração total da música em milissegundos.
danceability	Decimal (0 a 1)	Quão dançante a música é (ritmo constante, força da batida).
energy	Decimal (0 a 1)	Quão intensa e agitada é a faixa (músicas rápidas e ruidosas têm notas altas).
loudness	Decimal (dB, -60 a 0)	Volume acústico médio ponderado da gravação.
speechiness	Decimal (0 a 1)	Presença de palavras faladas (valores altos indicam fala/podcasts).
acousticness	Decimal (0 a 1)	Certeza de que a música foi gravada com instrumentos acústicos/desplugados.
instrumentalness	Decimal (0 a 1)	Ausência de voz (valores $> 0,5$ indicam faixas sem vocal).
liveness	Decimal (0 a 1)	Probabilidade da música ter sido gravada ao vivo diante de público.
valence	Decimal (0 a 1)	Positividade musical transmitida (músicas animadas e felizes têm notas altas).
tempo	Decimal (BPM)	Batidas por minuto (andamento rítmico da faixa).
key / mode	Inteiro	Tom e escala da composição (maior ou menor).
explicit	Booleano	Indica se a letra possui conteúdo adulto/explicito.

3. Preparação dos Dados e Engenharia de Features


3.1. Limpeza Inicial e Divisão das Bases

- Remoção de Identificadores Inertes:** As colunas de índices antigos (`Unnamed: 0`) e o identificador do Spotify (`track_id`) foram removidos para evitar que o modelo memorizasse códigos aleatórios.

2. **Remoção de Nulos:** Apenas uma única linha apresentava campos nulos e foi descartada, restando **113.999 faixas limpas**.

3. **Divisão Estratégica:**

- **Teste Final Cego (10% - 11.400 faixas):** Guardado separadamente e nunca tocado durante os treinos intermediários.
- **Treino (81% - 92.339 faixas):** Onde os algoritmos aprendem os padrões.
- **Validação (9% - 10.260 faixas):** Onde comparamos a performance dos modelos.



3.2. Target Encoding: Como foi feito e por que evita o Data Leakage

Os modelos de Machine Learning não entendem palavras diretamente como "The Beatles" ou "Rock". Era preciso transformar `artists` e `track_genre` em números.

- **Por que não One-Hot Encoding?** Se criássemos uma coluna para cada um dos 31.437 artistas, teríamos uma tabela com mais de 31.000 colunas preenchidas por zeros, estourando a memória e destruindo a velocidade das árvores.
- **A solução: Target Encoding** — substituímos o nome da categoria pela **média de popularidade histórica** que ela costuma ter.

1. Codificação do Gênero (Target Encoding Direto)

Como existem apenas 114 gêneros e cada gênero tem centenas de músicas na base de treino, a média de cada gênero é muito estável.

- Agrupamos as músicas de treino por gênero e tiramos a média de popularidade de cada um (*exemplo: Pop tem média 65, Rock tem média 60*).
- Criamos a coluna `genre_encoded` aplicando essas médias. Se na validação aparecer um gênero novo, preenchemos com a média global de todas as músicas (`global_mean = 33,27`).

2. Codificação do Artista: O perigo do Vazamento de Dados (*Data Leakage*)

Com os artistas, o perigo era enorme. Muitos artistas têm apenas 1 ou 2 músicas na base. Se pegássemos simplesmente a nota dessa única música para dizer a média daquele artista, o modelo não aprenderia nada — ele apenas "colaria a resposta da prova", gerando um sobreajuste (*overfitting*) severo.

3. A Solução: K-Fold Out-Of-Fold (OOF) Target Encoding

Para resolver isso de forma blindada, usamos o fatiamento em blocos cruzados (**K-Fold com 5 partes**):

1. O conjunto de treino foi dividido em **5 blocos iguais**.
2. Para calcular o peso do artista em uma música que caiu no **Bloco 1**, calculamos a média das músicas dele usando **apenas os Blocos 2, 3, 4 e 5**.
3. O valor calculado é gravado no Bloco 1. Esse processo é repetido para os 5 blocos.
4. **Por que isso é eficaz?** Porque nenhuma música jamais usa a sua própria nota para calcular a média do seu artista. O modelo é obrigado a olhar para o histórico prévio das outras músicas!

5. **E na Validação e Teste?** A validação simula o "futuro". No futuro, já temos o histórico consolidado do artista no passado. Por isso, na validação **não há divisão em folds**: aplicamos diretamente a média consolidada de 100% da base de treino. Artistas novos que nunca apareceram antes recebem a média global via `.fillna(global_mean)`.

4. Respostas às Guiding Questions

Com base nas análises exploratórias, no comportamento das variáveis e no modelo preditivo, respondemos às perguntas norteadoras do desafio:

GQ 1: Quais características musicais estão mais relacionadas à popularidade de uma música?

Resposta: As variáveis mais determinantes são, de forma ampla, o histórico do artista e o gênero (responsáveis por mais de 65% da importância preditiva). Dentre as características estritamente sonoras, tempo, speechiness (presença de voz) e loudness (volume) são as que apresentam maior influência nas estimativas do modelo.

Evidência: A Análise de Importância de Features do Random Forest aponta `artist_encoded` (56,57%) e `genre_encoded` (8,93%), seguidas por `tempo` (3,49%), `speechiness` (3,47%) e `loudness` (3,41%).

GQ 2: Músicas populares possuem um perfil sonoro diferente das músicas menos populares?

Resposta: Sim. As faixas do topo do ranking (*Popularity* > 60) apresentam padrões definidos: presença marcante de vocais (índice quase nulo de faixas puramente instrumentais), volume acústico elevado e comprimido, e duração concentrada entre 2,5 e 3,5 minutos.

Evidência: O perfil sonoro dominante das faixas de alta popularidade revela baixa instrumentalidade e alto volume comercial (loudness concentrado entre -5 dB e -7 dB).

GQ 3: Músicas mais dançantes tendem a ser mais populares?

Resposta: Não existe forte relação causal global. A dançabilidade atua como requisito básico de entrada para determinados gêneros, mas seu baixo peso no modelo comprova que ela, isoladamente, não garante sucesso (milhares de músicas altamente dançantes possuem popularidade próxima a zero).

Evidência: A correlação de Pearson de dançabilidade com popularidade é quase nula ($r = +0,035$) e a importância no modelo é de apenas 3,30%.

GQ 4: Músicas com maior energia tendem a ser mais populares?

Resposta: Não. A energia possui correlação estatística nula com a nota de popularidade. A análise evidencia que o parâmetro de energia ajuda a delimitar o gênero e a proposta da música, mas não eleva, isoladamente, o sucesso comercial (faixas calmas e acústicas também atingem popularidade global).

Evidência: Coeficiente de correlação ($r = +0,001$) estatisticamente quase nulo e baixa importância relativa preditiva (2,85%).

GQ 5: A popularidade do artista influencia a popularidade de suas músicas?

Resposta: Sim, de forma determinante. O histórico do artista, mensurado com base em Target Encoding, provou ser o motor central do modelo. Sem a presença da marca consolidada e base de fãs do artista, a previsibilidade a partir de áudio puramente isolado ficaria gravemente comprometida.

Evidência: O modelo Random Forest aponta que `artist_encoded` concentra a vasta maioria do poder preditivo (56,57% de Feature Importance).

GQ 6: A relação entre características musicais e popularidade muda de acordo com o gênero?

Resposta: Sim. O peso e as métricas acústicas de sucesso (como loudness e batidas fortes) mudam sob a ótica do gênero. A forte importância do gênero no modelo indica que as expectativas sonoras do público são altamente dependentes da categoria musical da faixa.

Evidência: O impacto das variáveis sonoras sofre controle da feature `genre_encoded`, que é a segunda feature mais importante (8,93%).

GQ 7: É possível prever se uma música será um hit usando características musicais?

Resposta: É possível estimar a faixa de popularidade com boa precisão média, explicando quase dois terços do fenômeno. Os aproximadamente 35% de erro restante indicam a presença de influências mercadológicas e sociais externas, imprevisíveis apenas com os dados fornecidos.

Evidência: O modelo otimizado Random Forest atinge um erro médio absoluto (MAE) de apenas 8,06 pontos (escala de 0 a 100) e explica 64,24% (R^2) da variação de popularidade.

GQ 8: Como os valores zerados/ausentes na variável de popularidade afetam a previsão?

Resposta: A variável alvo (popularidade) possui uma grande quantidade de valores zerados (fenômeno *zero-inflated*). Modelos de regressão padrão têm dificuldade em prever exatamente 0 em massa. Em vez disso, geram previsões contínuas muito baixas (mas maiores que zero), o que aumenta a margem de erro (resíduos) na cauda inferior, prejudicando o ajuste perfeito do modelo.

Evidência: A assimetria e concentração anormal de notas zero na distribuição original de `popularity` versus as previsões contínuas do Random Forest.

GQ 9: Qual algoritmo de Machine Learning demonstrou melhor desempenho preditivo neste cenário e por quê?

Resposta: O Random Forest Regressor demonstrou desempenho superior pois seu mecanismo baseado em inúmeras árvores e votos aleatórios conseguiu capturar as complexas relações não lineares das variáveis de áudio. Ademais, ele obteve maior imunidade ao overfitting se comparado aos demais avaliados.

Evidência: O Random Forest (Bagging) obteve MAE de 8,06 e R^2 de 64,24%, com menor raiz do erro quadrático médio (RMSE = 13,39) comparado ao baseline Linear e aos Boostings (XGBoost, LightGBM).

GQ 10: Como a engenharia de dados impediu o "Data Leakage" (vazamento de dados) ao analisar o histórico dos artistas?

Resposta: Ao particionar a base em cinco blocos independentes, o peso histórico do artista em uma música específica é calculado estritamente sobre suas faixas localizadas nos demais quatro blocos. Dessa forma, o algoritmo extrai tendências globais do artista sem utilizar a própria faixa, forçando a generalização.

Evidência: Utilização da técnica Target Encoding Out-Of-Fold, dividindo o treino em 5 blocos (K-Fold K=5).

GQ 11: O tempo de duração de uma música (`duration_ms`) é um fator determinante para seu alcance massivo?

Resposta: Não de forma isolada e definitiva. Ainda que as músicas populares concentrem o padrão entre 2,5 e 3,5 minutos, a métrica serve apenas de papel complementar ao som, sendo uma moduladora coadjuvante da experiência (compatibilidade temporal das rádios e streamings).

Evidência: No Random Forest, a variável `duration_ms` apresentou uma importância relativa moderada de 3,27%.

GQ 12: Músicas com predomínio instrumental enfrentam maior barreira comercial em comparação a músicas com vocais explícitos?

Resposta: Sim. O conjunto de dados reforça a dificuldade comercial das faixas sem vocais para o catálogo e popularidade gerais de "mass market". A falta de instrumentais consolida que o apelo de massa exige o vocal cantado, deixando os instrumentais relegados a nichos bem delimitados.

Evidência: O parâmetro `instrumentalness` possui a menor relevância preditiva no modelo (2,42%) em conjunto a uma notável ausência no perfil macro do topo de ranking (músicas populares não demonstram alta instrumentalidade).

GQ 13: Qual o salto de precisão trazido pelos modelos ensemble em comparação ao modelo de baseline matemático tradicional (Regressão Linear)?

Resposta: Ocorreu um ganho substancial em capturar padrões. A Regressão Linear falha na captura de combinações lógicas (como a intersecção de gênero, artista e BPM), e o modelo de ensemble conseguiu entender que o sucesso se dá pela sinergia (interação combinada) destas variáveis, e não pela regressão em linhas estáticas separadas.

Evidência: A Regressão Linear conseguiu explicar apenas 57,37% da variância (R^2) com um erro médio (MAE) de 9,69; enquanto o Random Forest obteve R^2 de 64,24% e MAE de 8,06.

GQ 14: Existem fatores determinantes de popularidade que são invisíveis aos parâmetros técnico-musicais fornecidos pelo Spotify?

Resposta: Certamente. A limitação na captura final de variância reflete fatores do ecossistema extrínseco. Orçamentos de marketing de selos de gravadoras, impacto de dancinhas (Tiktok),

hype socioculturais ou mesmo o apoio à curadoria da plataforma definem esse percentual fantasma do fenômeno que a Inteligência Artificial, limitada ao áudio e base quantitativa do Spotify, não captura.

Evidência: O melhor R^2 obtido pela base de dados estática tangenciou os 64%, sugerindo matematicamente a presença de aproximadamente 36% da variância total como inexplicada pelo modelo de IA.

GQ 15: Por que o modelo explica apenas 64% da variação de popularidade?

Resposta: Esse limite explicativo ocorre pela combinação da natureza da distribuição de popularidade (o excesso de zeros discutido na GQ 8, que aumenta o erro basal do modelo) somada aos fatores sociais e de mercado externos aos dados de áudio fornecidos. Dessa forma, 64% de poder explicativo representa um teto consideravelmente alto para variáveis estritamente técnico-musicais.

Evidência: O teto de R^2 de 64,24% no modelo Random Forest validado via validação cruzada, cruzado com as observações da distribuição de dados e impacto mercadológico.

5. Escolha e Funcionamento do Random Forest

Para a tarefa de prever a popularidade, avaliamos modelos lineares, árvores de decisão simples, ensembles de Boosting e a Floresta Aleatória.

Por que o Random Forest Regressor foi a escolha ideal?

- Capacidade de capturar relações não-lineares:** Como vimos, as métricas de áudio isoladas não têm correlação linear com a popularidade. O Random Forest consegue criar regras combinadas complexas, como: *"Se o artista tem nota > 50, o gênero é Dance e a dançabilidade é > 0,7, a popularidade sobe"*.
- Imunidade a diferentes escalas de dados:** O dataset mistura milissegundos (`duration_ms` de 200.000), decibéis (`loudness` em torno de -8) e decimais (`valence` de 0 a 1). Modelos lineares exigem normalização complexa; o Random Forest opera dividindo os valores por comparação ($>$ ou $\leq$), sem depender da escala das variáveis.
- Controle de Overfitting por Votação (Bagging):** Uma única árvore de decisão costuma memorizar demais os dados de treino. O Random Forest cria **100 árvores independentes**, onde cada uma treina com uma amostra aleatória de músicas e seleciona um grupo aleatório de

colunas em cada divisão. O resultado final é a **média dos palpites das 100 árvores**, o que reduz os erros e estabiliza a previsão.

4. **Interpretabilidade Prática:** O algoritmo permite extrair com facilidade a importância de cada coluna para responder às perguntas de negócio.

6. Validação Cruzada K-Fold e Comparação dos Modelos

6.1. O que é a Validação Cruzada (K-Fold Cross-Validation)?

Em vez de confiar apenas em uma única divisão de teste (que poderia dar sorte ou azar com a escolha das músicas), aplicamos o **K-Fold Cross-Validation (K=5)** com Pipeline :

- A base de desenvolvimento é repartida em 5 partes.
- Em 5 rodadas sucessivas, 4 partes treinam o modelo e 1 parte serve de teste.
- O TargetEncoder é recalculado dentro de cada fold para garantir zero contaminação.
- Ao final, calculamos a **média e o desvio padrão** das métricas em todas as rodadas, comprovando que o modelo tem desempenho consistente em qualquer fatia de dados.

6.2. Tabela de Desempenho Comparado dos Modelos

Abaixo estão os resultados consolidados na base de validação para todos os algoritmos avaliados no projeto:

Modelo	MAE (Erro Médio)	RMSE (Penaliza Erros Grandes)	R^2 (Poder de Explicação)	R^2 (%)	Tempo de Treino
Random Forest (Bagging)	8,06 pts	13,39 pts	0,6424	64,24%	~17 s
XGBoost (Boosting)	8,63 pts	13,78 pts	0,6213	62,13%	~0,5 s
LightGBM (Boosting)	8,70 pts	13,84 pts	0,6179	61,79%	~0,5 s

Modelo	MAE (Erro Médio)	RMSE (Penaliza Erros Grandes)	R^2 (Poder de Explicação)	R^2 (%)	Tempo de Treino
Árvore de Decisão	8,80 pts	14,42 pts	0,5848	58,48%	~0,6 s
Regressão Linear (Baseline)	9,69 pts	14,62 pts	0,5737	57,37%	~0,04 s

Interpretação das Métricas:

- **MAE (Erro Médio Absoluto):** O Random Forest erra, em média, apenas **8 pontos** na nota da música (de 0 a 100).
- **RMSE (Raiz do Erro Quadrático):** Mede a penalidade para erros graves. O Random Forest obteve o menor valor (13,39), demonstrando que é o modelo mais estável e que menos comete erros absurdos.
- **R^2 (Poder Explicativo):** Com **64,24%**, o Random Forest superou todas as alternativas e foi consagrado como o modelo definitivo do projeto.

7. O que Realmente Importa: Análise de Importância das Features

Ao analisar quais colunas o Random Forest mais consultou para tomar suas decisões, temos a resposta definitiva sobre a mecânica do sucesso musical:

Importância das Variáveis no Random Forest:


artist_encoded	[██]	56,57%
genre_encoded	[████]	8,93%
tempo	[██]	3,49%
speechiness	[██]	3,47%
loudness	[██]	3,41%
acousticness	[██]	3,37%
danceability	[██]	3,30%
valence	[██]	3,29%
duration_ms	[██]	3,27%
liveness	[██]	3,22%
energy	[██]	2,85%
instrumentalness	[██]	2,42%
key / mode / etc	[]	< 2,0%

Três Descobertas Cruciais:

- O Efeito Artista é Soberano (56,57%):** Mais da metade da nota de uma música vem do prestígio de quem a canta. Ouvintes consomem marcas e comunidades já formadas.
- O Gênero estabelece o Ponto de Partida (8,93%):** O estilo da música define a audiência potencial imediata da faixa.
- Áudio é Equilibrado (~3,3% cada):** Nenhuma característica sonora isolada faz mágica. Dançabilidade, energia, BPM e volume atuam em conjunto apenas para garantir que a música soe bem dentro do gênero escolhido.

8. Arquitetura Proposta para Produção

Para transformar esse estudo em um serviço funcional no mundo real, propomos a seguinte arquitetura de software:



Componentes Práticos:

- Camada de Machine Learning (Python / Scikit-Learn):** Executa o pipeline de treino, calcula os folds, gera o `modelo_rf.pkl` e exporta a base original para extração das médias de artistas e gêneros.

2. **Armazenamento de Features (CSV / Memória):** Os dados de Target Encoding extraídos de `dataset.csv` são carregados dinamicamente na inicialização da aplicação para traduzir textos em features numéricas.
3. **Backend API (FastAPI):** Microsserviço assíncrono e leve em Python que recebe as requisições, aplica a transformação usando os dicionários de médias (Target Encoding) e aciona o modelo treinado para gerar a predição da popularidade instantaneamente.
4. **Interface de Usuário (Frontend React/Vite):** Uma aplicação SPA (Single Page Application) que substitui protótipos estáticos ou interfaces baseadas em Streamlit, oferecendo uma experiência de usuário (UX) rica e dinâmica que interage em tempo real via chamadas HTTP (POST) com o backend FastAPI.
5. **Proteção contra Falhas:** Caso a música seja de um artista estreante, o sistema no backend aplica automaticamente a média global (33,27), garantindo que a API nunca falhe ou retorne erro.


9. Visualizações Gráficas

Abaixo estão os principais gráficos gerados durante a Análise Exploratória de Dados e avaliação do modelo:

1. Distribuição da Variável Target (Popularidade)


Mostra a alta concentração de músicas com popularidade zero.

Distribuição de Popularidade (Zero-Inflated)




2. Matriz de Correlação

Revela as interações numéricas diretas entre as variáveis sonoras.




3. Importância das Variáveis (Feature Importance)

Evidencia o peso dominante do artista frente às características de áudio no modelo Random Forest.



4. Gráfico de Resíduos (Erro do Modelo)

Apresenta a diferença entre os valores previstos pelo modelo e a popularidade real.



10. Conclusão

O projeto comprovou com rigor metodológico que a popularidade de músicas no Spotify **pode ser estimada com alta acurácia por meio de Machine Learning**:

- O **Random Forest Regressor** foi o modelo campeão, atingindo **MAE = 8,06 pontos** e $R^2 = 64,24\%$.
- O uso de **Target Encoding com K-Fold Out-Of-Fold** foi fundamental para incorporar artistas e gêneros com segurança, blindando o modelo contra vazamento de dados.
- A hipótese de que o áudio sozinho explica o sucesso foi refutada: o motor do alcance musical é o **artista**, seguido pelo **gênero**, cabendo às variáveis acústicas o papel de adequação e acabamento técnico da produção.